

完整N糖肽修饰组学研究报告



项目编号: XB05498B2LP1g

质检反馈单编号: F20241104023V1


项目名称: 3个鸡蛋壳基质样本10X 完整N糖肽定量组学 (1组3次重复)

分析概述

糖类是自然界中最丰富也是结构最多样的一类分子,糖基化修饰是至关重要的翻译后修饰之一。生物体内约50%的蛋白可发生糖基化,其对生物维持正常的生理功能发挥举足轻重的作用,一直是修饰组学研究的焦点之一。在实际应用中,多种疾病诊断的生物标志物和蛋白质药物是糖蛋白,大量糖蛋白的特殊功能与疾病的相关性亟待深入解析。基于质谱的完整糖肽 (intact glycopeptides, IGP) 分析,可以同时获得糖基化位点及其对应糖型的完整信息,有助于获取糖链和糖基化位点间的对应关系,为生物标志物发现和疾病致病机理等研究提供更有力的研究基础。

技术路线

本研究通过蛋白提取、酶切、修饰肽段富集、液相色谱-质谱串联分析、生物信息分析等一系列前沿技术的有机结合,对样本进行修饰定量组学进行研究。其技术路线如下图所示:



分析流程

基于质谱检测得到Raw文件后, 1) 首先根据样本来源情况构建样本特异性蛋白数据库, 然后采用分析软件进行数据库搜索; 2) 接着基于数据库搜索结果进行肽段、完整糖肽的质控分析; 3) 完整糖肽的糖型分类和异质性分析; 4) 进行完整糖肽的定量分析, 包括定量分布和重复性分析, 同时展示样本定量强度值分布结果; 5) 对鉴定到的蛋白进行常见功能注释, 包括GO、KEGG、Protein domain、COG/KOG、Reactome、WikiPathways、HallMark 以及转录因子 (Transcription factor, TF) 注释等, 其中Reactome、WikiPathways、HallMark 以及转录因子仅针对部分物种提供相关生信分析, 并对鉴定到的修饰位点进行motif分析; 6) 根据定量结果进行两组间差异倍数 (Fold Change, FC) 和T-test显著性P value值计算, 按照设定的阈值进行完整糖肽差异筛选, 绘制差异分析相关统计图, 若样本有3个分组及以上, 同时提供单因素方差分析 (ANOVA) 计算多组别的显著性P value值, 根据ANOVA P value筛选多组间的差异完整糖肽进行后续相关分析; 7) 对五种糖型差异修饰蛋白进行功能分类统计分析, 包括GO二级分类、亚细胞定位分类、COG/KOG分类和KEGG通路分类统计; 8) 对差异修饰蛋白采用费希尔精确检验 (Fisher's exact test) 方法进行富集分析, 涉及的功能为GO、KEGG、Protein domain、Reactome和WikiPathways; 9) 通过富集聚类分析比较同一比较组内不同糖型下的差异修饰蛋白在功能上的联系; 10) 通过蛋白互作网络 (Protein-protein interaction, PPI) 分析, 筛选出特定实验条件下的关键调控修饰蛋白。生信分析流程如下图:



注：1) 蛋白质数据库由客户提供或来源于UniProt数据库。若UniProt数据库中没有该物种，需要客户指定数据库来源（其他物种特异性数据库、转录组测序等）。2) 若项目无生物学或技术重复，则不能进行定量重复性分析。3) 红色星标的分析内容有条件限制，若与分析描述相对应的图片缺失，说明数据无法绘制该类型的图。4) 本项目具体分析内容以此报告为准。

结果展示

数据库检索


搜库原理介绍：质谱分析可以获得样本中肽段的质量和信号强度、以及肽段碎裂后碎片离子的质量和信号强度。我们通常把肽段水平的信息叫做一级谱，肽段碎片离子信息叫做二级谱。谱图中包含的信息非常复杂，我们需要借助数据库才能正确解析出谱图潜在包含的肽段序列。在搜索前，根据数据库中的蛋白序列构建理论的二级谱数据库。然后将质谱产生的二级谱与理论二级谱图进行搜索比对，通过算法打分过滤后获得正确匹配的理论肽段序列。通过鉴定到的蛋白特异性肽段，可以识别出包含的蛋白信息。

数据库检索是一个复杂的计算过程，需要采用专业的质谱数据分析软件进行数据解析。质谱下机原始数据导入搜库软件，根据实验方案设定相应的分析参数。本次实验二级质谱数据使用MSFragger (v3.4)进行检索。检索参数设置：数据库为Gallus_gallus_9031_PR_20240807.fasta (43711条序列)，添加了反库以计算随机匹配造成的假阳性率 (FDR)，并且在数据库中加入常见的污染库，用于消除鉴定结果中污染蛋白的影响；酶切方式设置为Trypsin/P；漏切位点数设为2；肽段最小长度设置为7个氨基酸残基；肽段最大修饰数设为3；一级母离子和二级碎片离子的质量误差容忍度设为20 ppm。将半胱氨酸烷基化Carbamidomethyl (C)设置为固定修饰，可变修饰为甲硫氨酸的氧化，蛋白N端的乙酰化。将mass offsets设置为糖基化修饰列表。蛋白鉴定、PSM鉴定的FDR都设置为1%。

为了得到高质量的分析结果，搜库分析结果需要做进一步的数据过滤。下表是搜库结果经过数据过滤后的鉴定的完整糖肽总体情况。

表：完整糖肽鉴定总览

表头说明: 1. Identified intact glycopeptides: 鉴定完整糖肽数； 2. Comparable intact glycopeptides: 可定量比较的完整糖肽数； 3. Identified proteins: 鉴定蛋白数； 4. Comparable proteins: 可定量比较的蛋白数； 5. Unique Glycans: 鉴定糖链的种类，详见MS表“Observed Modification”列。



数据质控

质谱结果质控


质谱下机的数据，在搜库完成后，需要进行一系列质控，保证结果质量符合标准：包括肽段长度分布，修饰位点个数分布和修饰位点糖链个数分布。

肽段长度分布

修饰位点个数分布


修饰位点糖链个数分布

大部分肽段带2-3个电荷，肽段分布在7-20个氨基酸，符合基于酶解和质谱碎裂方式的一般规律。质谱鉴定到的肽段长度的分布符合质控要求。



UniProt验证N糖基化修饰位点


本项目鉴定的N糖基化修饰位点总量如图像最上方所示，柱状图中浅蓝色对应数量的N糖基化修饰位点是在本项目中新发现的，深蓝色对应数量的N糖基化修饰位点在UniProt数据库中存在注释（其中绿色柱状图左侧表示UniProt数据库文献支持的注释，右侧表示由NetNGlyc算法基于序列上下文预测得到的注释）。结果详见2-Basic_analysis/GlycanType_analysis/UniProt Verify Barplot.png。



糖型分类

由于相同蛋白在生物体内可能存在多个拷贝，而糖基化受到包括：多肽翻译、蛋白折叠、糖基转移酶的位置和竞争关系、糖苷酶的位置和浓度、跨膜转运等多种因素调控，因此蛋白的同一修饰位点上可能存在不同糖链（即不同的Observed Modification）。具体结果详见2-Basic_analysis/MS_identified_information.xlsx。下面的糖型分类统计柱状图展示本项目中每类糖型的数量，图像横轴为数量统计（所有蛋白所有位点的同类糖型总量），纵轴为5类糖型。结果详见2-Basic_analysis/GlycanType_analysis/Number of each glycan type.png。

将鉴定到的糖链（Observed Modification），基于糖链的特征，将其划分为5类糖型（Paucimannose, High mannose, Complex/hybrid, Fucosylated, Sialylated），依据参考文献：Capturing site-specific heterogeneity with large-scale N-glycoproteome analysis中的分类方式。**基于Glygen数据库提取糖链对应的结构图像，由于糖结构的复杂性和多样性，通常一个糖链可能在数据库有多个匹配，我们优先输出数据库分类为N-linked，且得分最高的糖结构图像。若糖链在数据库中不存在N-linked分类的图像，我们也输出得分最高的其它分类糖结构图像，仅限参考。**具体可查阅2-Basic_analysis中Annotation_Glygen.xlsx表格，通过在列名Observed Modification中查询感兴趣的糖链，可获得GlycanImage列中对应的糖结构。




糖型异质性分析

基于糖型的5类划分，探索糖基化修饰位点的糖型异质性。

糖型共发生热图

蛋白的糖型异质性散点图

本项目共有48个位点存在多种糖型，基于这些位点，统计糖型间的共发生频率，揭示不同糖型间的微观异质性 (microheterogeneity)。图中每行/列都代表一个糖型，用不同颜色代表糖型的5种类型，热图中颜色越深表示糖型的共发生频率越高。结果详见2-Basic_analysis/GlycanType_analysis/Co-occurrence Heatmap Triangle.png。



定量分析

搜库结果中给出了每个完整糖肽在不同样本中的信号强度值Intensity。根据这个信息通过如下步骤计算出完整糖肽的相对定量值：

1. 首先完整糖肽在不同样本中的信号强度值 (I) 通过中心化变换后，得到完整糖肽在不同样本中的相对定量值 (R)。计算公式如下：其中*i*表示样本，*j*表示完整糖肽。 $[R_{ij}] = [I_{ij}] / \text{Mean}(I_j)$
2. 若样本同时进行了蛋白组学和修饰组学检测，通常会用完整糖肽相对定量值除以该完整糖肽对应蛋白的相对定量值，以消除蛋白表达对完整糖肽表达的影响（注：详见2-Basic_analysis/MS_identified_information.xlsx文件中是否含有蛋白相对表达值）。

样品重复性检验


该项目无重复样本。

强度值分布

为了探究不同样本间完整糖肽强度值的分布及差异性，我们提取各样本的完整糖肽强度值，分别采用箱线图、小提琴图，分布柱状图和密度分布曲线图的形式进行展示。


箱型图 **小提琴图** **分布柱状图** **密度分布曲线图**

横轴为样本名称，纵轴为经Log10转换后的强度值，箱体的颜色代表不同的分组，横向比较可以粗略地看出组内和组间数据分布的分散程度，若样本均值在同一水平线，说明样本质量良好。



蛋白功能注释

为了透彻了解不同蛋白质的功能特性，我们对鉴定到的蛋白质进行全方位的功能注释。包含基因本体论（Gene Ontology, GO）、蛋白结构域（Protein domain）、KEGG通路、COG/KOG功能分类、亚细胞结构定位（Subcellular localization）、Reactome、WikiPathways、HallMark 以及转录因子（Transcription factor, TF）等方面进行了详细的注释。注：Reactome、WikiPathways、HallMark 以及转录因子仅针对部分物种，其中如果蛋白是转录因子，在3-Functional_annotation/Annotation_combine.xlsx文件的“Is_TF”列会标记为“Transcription factor”，反之则为空。若没有展示相关的分析结果，说明本项目的数据无法获得相关注释信息。各项功能注释涉及到的软件、数据库和版本信息详见材料方法部分的生物信息学分析方法的表：功能注释软件信息表。注释结果详见文件“3-Functional_annotation/Annotation_combine.xlsx”。




Motif分析

大规模的修饰组学实验可以在一次实验中鉴定出数千个蛋白质翻译后修饰位点，了解引起这些修饰的潜在生物学过程是蛋白质组学的重要研究方向，例如了解酶对其底物的偏好性可以帮助阐明它们涉及的生物途径。由于酶对给定底物的部分生化偏好可能是由修饰位点周围的残基决定的，因此生物化学家将研究重点放在确定引起特定酶-底物相互作用的关键相邻残基上，这种蛋白或多肽序列形成的特定残基模式称为基序（Motif）。

使用基于motif-x算法的MoMo分析工具，分析修饰位点的基序特征。所有鉴定到的修饰位点上下游各10个氨基酸组成的肽段序列作为分析对象；分析背景为物种中所有潜在发生修饰位点上下游各10个氨基酸组成的肽段序列。当某个特征序列形式的肽段数量大于20，且统计学检验P值小于0.000001时，认为该特征序列形式为修饰肽段的一种基序。详见：3-Functional_annotation/Motif_analysis。

特别的，由于N糖基化修饰发生在天冬酰胺(Asn)的侧链氨基上，且符合N^[^P][STC]的序列规律，其中第二位表示不为脯氨酸P的任意氨基酸，第三位为丝氨酸S、苏氨酸T或半胱氨酸C，其中半胱氨酸C比较少见，因此N糖基化修饰的motif有其独特的序列特征。

基于MoMo分析结果，采用热图形式展现了修饰位点附近氨基酸出现频率变化程度打分（DS）。DS计算公式如下： $\text{DS} = -\text{Log}_{10}(\text{p.value}) * \text{sign}(\text{diff.percent})$



差异完整糖肽筛选

三次重复及以上：将完整糖肽在两组样本中的相对定量值的均值之比作为差异倍数（Fold Change, FC ）。例如计算样本分组A与样本分组B之间完整糖肽的差异倍数。计算公式如下：其中 R 表示完整糖肽相对定量值， i 表示样本， k 表示完整糖肽。 $\text{FC}_{\{A/B,k\}} = \text{Mean}(R_{\{i,k\}}, i \in A) / \text{Mean}(R_{\{i,k\}}, i \in B)$ 为了判断差异的显著性，将完整糖肽在两组样本中的相对定量值进行T检验，计算相应的 P value，以此作为显著性指标，默认 P value < 0.05。为了让检验数据符合T检验需求的正态分布。检验前，完整糖肽相对定量值需要经过Log2对数转换。计算公式如下： $\text{P}_{\{k\}} = T.\text{test}(\text{Log}_2(R_{\{i,k\}}, i \in A), \text{Log}_2(R_{\{i,k\}}, i \in B))$

两次重复：将完整糖肽在两组两次重复中的比值的均值作为差异倍数（Fold Change, FC ）。例如计算样本分组A与样本分组B之间完整糖肽的差异倍数。计算公式如下：其中 R 表示完整糖肽相对定量值， i 表示样本， k 表示完整糖肽。 $\text{FC}_{\{A/B,k\}} = \text{Mean}((R_{\{i,k\}}, i \in A) / (R_{\{i,k\}}, i \in B))$ 为了判断差异的显著性，将每个完整糖肽在比较组中的标准变异系数（CV）作为显著性指标，默认 $CV < 0.1$ 。计算公式如下： $\text{CV}_{\{k\}} = \text{SD}(A_{\{1k\}}/B_{\{1k\}}, A_{\{2k\}}/B_{\{2k\}}) / \text{Mean}(A_{\{1k\}}/B_{\{1k\}}, A_{\{2k\}}/B_{\{2k\}})$


无重复：将完整糖肽在两个样本中的相对定量值之比作为差异倍数（Fold Change, FC ）。例如计算样本A与样本B之间完整糖肽的差异倍数。计算公式如下：其中 R 表示完整糖肽相对定量值， k 表示完整糖肽。 $\text{FC}_{\{A/B,k\}} = R_{\{Ak\}} / R_{\{Bk\}}$ 通过上述差异分析，以差异表达量变化超过1.5作为显著上调的变化阈值，小于1/1.5作为显著下调的变化阈值。本项目所有比较组差

异完整糖肽筛选结果详见文件4-Differentially_expressed_IGPs/Two_Group_Comparison/Differentially_expressed_statistics.xlsx，差异表达的完整糖肽汇总数据见下表。

(%%diff%%)

- 差异完整糖肽统计图
- 差异完整糖肽散点图
- 差异完整糖肽热图
- 差异完整糖肽雷达图


通过前面一系列的数据处理和阈值选择，统计每个比较组的差异信息绘制柱状图展示，可直观对比不同比较组间的差异完整糖肽分布。



差异修饰蛋白功能分类

针对每个比较组筛选出的差异完整糖肽5类糖型对应的修饰蛋白进行GO二级分类、亚细胞定位分类、COG/KOG分类和KEGG通路分类分析，同时将每类糖型的差异上调和差异下调的分类结果进行对比展示，结果以条形图、饼图、玫瑰图和柱状图的形式进行展示，若与分析描述相对应的图片缺失，说明数据无法绘制该类型的图。

- GO二级分类
- 亚细胞结构注释分类
- COG/KOG功能分类
- KEGG通路分类
- G3vsG1
- G2vsG1
- G2vsG3
- High_mannose
- Complex_hybrid
- Fucosylated
- Sialylated
- Paucimannose
- 分类条形图
- 分类柱状图



横轴为差异修饰蛋白在分类中的数目，纵轴表示GO的一级分类（Biological process/Cellular component/Molecular function）中的二级功能分类。图中用不同颜色表示了GO的一级分类。详见：5-Functional_classification/*/*/*-GO_classify.png。

差异修饰蛋白功能富集分析

我们对各比较组中5类差异糖型对应的修饰蛋白分别进行了GO分类、KEGG通路、蛋白结构域、Reactome和WikiPathways五个层面的富集分析，其中Reactome和WikiPathways分析仅针对部分物种样本提供，此处运用Fisher's exact test即费希尔精确检验计算显著性P value，目的是发现差异表达修饰蛋白是否在某些功能类型有显著性的富集趋势。通过气泡图、条形图、弦图和Circos图的形式进行结果展示，不区分糖型的差异功能富集分析结果详见6-Functional_enrichment/*/*/*All文件夹，若与分析描述相对应的图片缺失，说明数据无法绘制该类型的图。

GO富集

KEGG 通路富集

蛋白结构域富集

G3vsG1

G2vsG1

G2vsG3

High_mannose

Complex_hybrid

Fucosylated

Sialylated

Paucimannose

富集气泡图

富集条形图

富集弦图

富集Circos图

KEGG 富集通路图

对上述富集分析得到的KEGG通路通过网页形式进行了可视化展示，每种糖型按照字符排序展示top15的通路结果，图中红色填充表示差异修饰上调蛋白；蓝色填充表示差异修饰下调蛋白；黄色填充表示此节点既包含差异修饰上调蛋白又包含差异修饰下调蛋白（注：随着KEGG官网的更新，注释的颜色可能与图片中的方框存在偏差）。详见：7-Enrichment_pathway_image/，结果展示如下：

G3vsG1

G2vsG1

G2vsG3

High_mannose

Complex_hybrid

Fucosylated

Sialylated

Paucimannose

聚类分析

将每个比较组中的5类差异糖型对应的蛋白进行GO分类、KEGG通路、蛋白结构域、Reactome和WikiPathways富集后，我

们对其进行聚类分析，旨在找到比较组内5类差异糖型之间其对应的蛋白功能的异同，详见：8-Functional_enrichment_cluster/。

聚类方法：根据富集分析得到的费希尔精确检验P value使用层次聚类的方法将不同糖型中的相关功能聚到一起，绘制成热图（heatmap）。热图的横向为不同的糖型，纵向为不同糖型中差异糖型对应的蛋白富集到的相关功能，如GO、KEGG pathway、Protein domain、Reactome和WikiPathways的描述，其中Reactome和WikiPathways仅针对部分物种样本提供。不同糖型与差异糖型对应的蛋白富集的功能描述对应的色块表示富集显著性高低。蓝色代表富集显著性高，蓝白色代表富集显著性低，*表示P value <0.05，**表示P value <0.01，***表示P value <0.001。

G3vsG1


G2vsG1

G2vsG3

Combine

Separated

KEGG pathway




蛋白互作网络分析

将比较组中根据差异倍数1.5筛选得到的差异修饰蛋白数据库编号或蛋白序列，通过与STRING蛋白互作网络数据库比对后，按照 confidence score > 0.7（high confidence）提取得到差异修饰蛋白互作关系。然后通过R package “visNetwork” 工具对差异修饰蛋白互作网络进行可视化展示。如下图所示：图中圆圈表示差异修饰蛋白，不同颜色代表蛋白的差异表达情况（蓝色为下调修饰蛋白，红色为上调修饰蛋白，黄色表示同时包含上下调完整糖肽的修饰蛋白），圆圈的大小表示与其互作的蛋白个数。为了能清晰的展示蛋白与蛋白之间的互作关系，我们筛选出了前50个互作关系最紧密的蛋白绘制了蛋白互作网络，详见：9-PPI/。

G3vsG1

G2vsG1

G2vsG3



报告解读

此报告相关解读视频见 <https://www.ptm-biolab-css.com.cn/cloud/cloudClass>

此报告相关解读文档见 <https://www.ptm-biolab-css.com.cn/cloud/cloudResource>

材料方法

实验方法

生物信息学分析方法

材料与试剂

表：常用试剂供应商列表(本项目实际使用试剂详见实验描述)

蛋白提取

样品从-80℃取出，各组样品分别加入4倍体积裂解缓冲液（1% SDS，1%蛋白酶抑制剂，3 μM TSA，50 mM NAM），超声裂解。4℃，12000 g离心10 min，上清液转移至新的离心管，利用BCA试剂盒进行蛋白浓度测定。

胰酶酶解

各样品蛋白取等量进行酶解，用裂解液将体积调整至一致，加入1倍体积的预冷丙酮，涡旋混匀后再加入4倍体积的预冷丙酮，-20℃沉淀2h。4500g，离心5min，弃上清，用预冷的丙酮洗涤沉淀2-3次。晾干沉淀后加入终浓度200 mM的TEAB，超声打散沉淀，以1:50的比例（蛋白酶：蛋白，m/m）加入胰蛋白酶，酶解过夜。加入二硫苏糖醇（DTT）使其终浓度为5 mM，56℃还原30 min。之后加入碘乙酰胺（IAA）使其终浓度为11 mM，室温避光孵育15 min。

HPLC分级

该项目未进行HPLC分级。

修饰富集

将肽段溶解在200 μL富集缓冲溶液中（80%乙腈/5%三氟乙酸），转移上清液至亲水（HILIC）微柱中，1000 g离心约15min完成富集。接着使用富集缓冲液洗涤亲水微柱3次。然后使用分别使用0.1%三氟乙酸，50mM 碳酸氢铵溶液和50%乙腈洗脱糖肽，收集合并洗脱液并真空冷冻抽干。最后，按照C18 ZipTips说明书除盐，真空冷冻抽干后供液质联用分析。

液相色谱-质谱联用分析

肽段用液相色谱流动相A相溶解后使用Vanquish Neo超高效液相系统进行分离。流动相A为含0.1%甲酸的水溶液；流动相B为含0.1%甲酸和80%乙腈的水溶液。液相梯度设置：0-0.75 min，4.0%B；0.75-0.90 min，4.0%-8.0%B；0.90-1.35 min，8.0%-8.5%B；1.35-20.85 min,8.5%-22.5%B；20.85-31.35 min，22.5%-35%B；31.35-31.95 min，35.0-55.0%B;31.95-32.70 min,55.0-99.0%B;32.70-34.00 min,99.0%B，流速维持在400 nl/min。肽段经由超高效液相系统分离后被注入NSI离子源中进行电离，然后进入Orbitrap Astral质谱进行分析。离子源电压设置为1900 V，肽段母离子使用Orbitrap检测器进行检测和分析，二级碎片离子使用Astral检测器进行检测和分析。一级质谱扫描范围设置为700-2000 m/z，扫描分辨率设置为240000；二级质谱扫描范围固定起点为120 m/z，二级扫描分辨率设置为80000。数据采集模式使用数据依赖型扫描（DDA）程序，Cycle Time设置为0.6 s。为了提高质谱的有效利用率，自动增益控制（AGC）设置为100%，信号阈值设置为25000 ions/s，最大注入时间设置为5 ms，串联质谱扫描的动态排除时间设置为15 s避免母离子的重复扫描。

对于开展进一步研究的建议（供参考）

如项目报告所陈述，您的项目在蛋白质组学分析的层面上已相对完整周详。基于项目的现有数据，如果您计划开展进一步的研究工作，我们提出如下建议供您参考：

功能蛋白筛选的一般性原则

1. 选取蛋白表达或修饰水平显著差异的蛋白,建议至少选取5个蛋白或修饰位点加以验证^{1,2}。
2. 可优先选取功能上已有相关报道或者与本研究实验体系有潜在关系的蛋白。
3. 选取生物信息学分析中得到的某些特定功能、通路、组分中差异表达显著的关键蛋白。
4. 选取功能上与某一特定生物学过程密切相关的蛋白，如信号通路中的受体蛋白、重要转录因子或者酶等。
5. 选取该蛋白是某重要蛋白复合物的核心蛋白。
6. 关于目的蛋白修饰位点的选择，可优先考虑该修饰位点位于目的蛋白的重要功能域、与其它蛋白相互作用的domain、酶蛋白的活性催化中心等关键功能调控区域³。

蛋白质表达或蛋白质修饰定量改变验证的基本方法

1. 筛选出目的蛋白后，可采用基于抗体的Western Blot、免疫组化、ELISA等方法验证不同样品（如实验组和对照组）中蛋白表达差异。当没有现成抗体可使用时，可以考虑使用RT-PCR方法来验证，但是由于存在转录后调控、蛋白质翻译水平调节和蛋白质降解等现象，转录水平的变化和蛋白水平的变化未必能完全对应。
2. 筛选出修饰位点之后，可利用基于蛋白质修饰的位点特异性抗体的Western Blot、免疫组化、ELISA等方法验证不同样品（如实验组和对照组）中蛋白质修饰的差异。对于没有现成位点特异性抗体可以使用的，可以考虑将目的蛋白IP下来后使用蛋白质修饰的泛抗体WB来检测⁴。这种方法实际检测的是该蛋白的整体修饰水平，但由于一个蛋白可能存在多个同种修饰位点，因此这种验证方式未必准确可靠。此外，也可以考虑将目的蛋白IP下来后采用质谱定量分析的方法进一步确定修饰水平的改变程度。

目的蛋白功能研究的一般性建议

1. 分子生物学层面：对于表达水平差异的蛋白质的研究，可使用反向遗传学reverse genetics的方法（knockdown, knockout, CRISPR），观察基因改变后导致的表型变化，并结合目的基因回补实验，进一步证实目的蛋白与表型之间的关联。对于修饰水平差异的蛋白和位点，可以对该位点进行体外定点突变并在研究系统中引入点突变site mutant的方式加以研究，例如全蛋白定量位点S/T突变为A模拟非修饰状态，突变为D/E模拟组成型修饰状态；乙酰化位点K突变为R模拟非修饰状态，突变为Q模拟组成型修饰状态；琥珀酰化因为具有负电荷(酸性)，其修饰位点K突变为R模拟非修饰状态，而突变为E模拟组成型修饰状态^{3,5,6}。
2. 生物化学层面：生物化学层面首先要考虑的是目的蛋白的相互作用蛋白的鉴定，常见的方法是利用目的蛋白的内源性抗体，通过免疫沉淀（Immunoprecipitation, IP）结合质谱分析的方法鉴定相互作用蛋白；在没有内源性抗体的情况下，也可考虑采用引入带有标签的过表达目的蛋白的pull down实验并结合质谱分析的方法鉴定相互作用蛋白。如果目标蛋白是酶，可通过检测修饰前后目的蛋白的酶动力学参数变化，分析该修饰对酶活性的影响。某些酶蛋白修饰后，可能导致其稳定性会发生变化，间接对其活性产生影响。如果目的蛋白是某蛋白质修饰底物，则要考虑鉴定催化该底物修饰或去催化

该底物修饰的酶，如激酶 (kinase)、乙酰转移酶 (acetyltransferase, HAT)、去乙酰化转移酶 (deacetylase, HDAC)、甲基转移酶 (methyltransferase, KMT)、去甲基转移酶 (demethylase, KDMT)、E3连接酶 (E3 ligase) 等；此外，在表观遗传学领域，对于某蛋白质修饰的特异底物，在生化分析层面上还要考虑去鉴定与该修饰特异性结合的相互作用蛋白（称之为“阅读器”，reader），如与乙酰化基团特异结合的含有bromodomain的蛋白、与赖氨酸甲基化基团特异结合的含有chromodomain的蛋白等。这些特异的催化酶、去催化酶、“阅读器”蛋白的筛选与鉴定一方面可以根据文献报道来初步确定，然后进一步生化验证；另一方面也可利用免疫沉淀 (Immunoprecipitation, IP)、pull down等手段结合质谱分析寻找鉴定，为进一步的机制研究提供线索。此外，还可以利用结构解析或者软件预测等方式研究修饰基团对蛋白构象的影响。

3. 细胞生物学层面：利用免疫荧光 (Immunofluorescence, IF)、FRET等荧光标记手段对目标分子的亚细胞定位和实时动态变化进行分析，为功能机制的研究和蛋白质相互作用提供依据；敲除目的蛋白或引入目的蛋白的过表达突变体，在表型变化的层面上，观察目的蛋白表达水平改变或修饰水平的改变对细胞周期、细胞增殖、迁移、极性、凋亡以及细胞间通讯等过程的影响。
4. 模式生物实验层面：如果你筛选出的目的蛋白与肿瘤生成密切相关，则可以考虑通过构建基因敲除小鼠、肿瘤异种移植 (Xenograft Model) 模型，结合表型分析和生化功能研究，在动物模型中深入探索目的蛋白及相关信号通路在生理病理过程中的意义。在植物学领域，如可采用拟南芥为模式生物，通过构建目的蛋白的突变株，结合表型分析和生化功能研究，深入探索目的蛋白生物学功能。
5. 其他：建议结合各领域本身的特定研究方法，开展针对性验证实验。基于质谱数据的后续功能性研究，景杰生物选取了部分优秀的文章，其研究思路可供您参考（见References）。在有关蛋白质表达或蛋白质修饰定量改变验证、目的蛋白功能验证方面，景杰生物能够为您提供高质量的目录抗体或根据您的要求开展蛋白质修饰抗体的定制服务。景杰生物开发有世界上种类最全的修饰泛抗体和组蛋白位点特异性抗体用于实验验证。对于没有现成抗体的蛋白尤其是新型修饰位点来说，我们提供高质量的特异性抗体的定制服务，可以为后续的验证和功能学研究提供帮助。

References

1. Li, L. et al. SIRT7 is a histone desuccinylase that functionally links to chromatin compaction and genome stability. *Nat Commun* 7, 12235, doi:10.1038/ncomms12235 (2016).
2. Du, Y. et al. Lysine malonylation is elevated in type 2 diabetic mouse models and enriched in metabolic associated proteins. *Mol Cell Proteomics* 14, 227-236, doi:10.1074/mcp.M114.041947 (2015).
3. Song, L., Wang, G., Malhotra, A., Deutscher, M. P. & Liang, W. Reversible acetylation on Lys501 regulates the activity of RNase II. *Nucleic Acids Res* 44, 1979-1988, doi:10.1093/nar/gkw053 (2016).
4. Du, Y. et al. Lysine malonylation is elevated in type 2 diabetic mouse models and enriched in metabolic associated proteins. *Molecular & Cellular Proteomics* 14, 227 (2014).
5. Zhao, D. et al. Lysine-5 acetylation negatively regulates lactate dehydrogenase A and is decreased in pancreatic cancer. *Cancer Cell* 23, 464-476, doi:10.1016/j.ccr.2013.02.005 (2013).
6. Xiangyun, Y. et al. Desuccinylation of pyruvate kinase M2 by SIRT5 contributes to antioxidant response and tumor growth. *Oncotarget* 8, 6984-6993, doi:10.18632/oncotarget.14346 (2017).
7. Riley, N.M. et al. Capturing site-specific heterogeneity with large-scale N-glycoproteome analysis. *Nat Commun* 10, 1311. <https://doi.org/10.1038/s41467-019-09222-w> (2019)
8. Hui Zhang. et al. Proteogenomic characterization of pancreatic ductal adenocarcinoma. *Cell* P5031-5052. doi:<https://doi.org/10.1016/j.cell.2021.08.023> (2021)
9. Hui Zhang. et al. Integrated Proteomic and Glycoproteomic Characterization of Human High-Grade Serous Ovarian Carcinoma. *Cell Rep.* 33(3):108276. doi:<https://doi.org/10.1016/j.celrep.2020.108276>. (2020)
10. Riley, Nicholas M et al. Capturing site-specific heterogeneity with large-scale N-glycoproteome analysis. *Nature communications* vol. 10,1 1311. 21 Mar. 2019, doi:10.1038/s41467-019-09222-w
11. Sinha, Ankit et al. N-Glycoproteomics of Patient-Derived Xenografts: A Strategy to Discover Tumor-Associated Proteins in High-Grade Serous Ovarian Cancer. *Cell systems* vol. 8,4 (2019): 345-351.e4. doi:10.1016/j.cels.2019.03.011
12. Wozniak, Jacob M et al. Mortality Risk Profiling of Staphylococcus aureus Bacteremia by Multi-omic Serum Analysis Reveals Early Predictive and Pathogenic Signatures. *Cell* vol. 182,5 (2020): 1311-1327.e14. doi:10.1016/j.cell.2020.07.040

英文版实验方法模板（供参考）

以下实验方法仅供您英文文章撰写时参考，具体实验步骤及参数以中文版方法材料描述为准。

1 Experimental Procedures

1.1 Sample Preparation

1.1.1 Protein Extraction

The sample was grinded with liquid nitrogen into cell powder and then transferred to a 5-mL centrifuge tube. After that, four volumes of lysis buffer (1% SDS, 1% protease inhibitor cocktail) was added to the cell powder, followed by sonication three minutes on ice using a high intensity ultrasonic processor (Scientz). (Note: For PTM experiments, inhibitors were also added to the lysis buffer, e.g. 3 μ M TSA and 50 mM NAM for acetylation, 1% phosphatase inhibitor for phosphorylation). The remaining debris was removed by centrifugation at 12,000 g at 4 °C for 10 min. Finally, the supernatant was collected and the protein concentration was determined with BCA kit according to the manufacturer's instructions.

1.1.2 Trypsin Digestion

The protein sample was added with 1 volume of pre-cooled acetone, vortexed to mix, and added with 4 volumes of pre-cooled acetone, precipitated at -20°C for 2 h. The precipitate was washed 2~3 times with the pre-cooled acetone. The protein sample was then redissolved in 200 mM TEAB and ultrasonically dispersed. Trypsin was added at 1:50 trypsin-to-protein mass ratio for the first digestion overnight. The sample was reduced with 5 mM dithiothreitol for 30 min at 56 °C and alkylated with 11 mM iodoacetamide for 15 min at room temperature in darkness. Finally, the peptides were desalted by Strata X SPE column.

1.1.3 TMT Labeling

The project did not do TMT labeling.

1.1.4 HPLC Fractionation

The project is not HPLC rated.

1.1.5 Affinity Enrichment

Tryptic peptides were redissolved in 200 μ L washing buffer (80% ACN, 5% TFA) and then loaded onto the column and then washed with washing buffer for three times. Glycopeptides were eluted with 0.1% TFA, 50mM ammonium bicarbonate and 50% ACN for two times. The eluted glycopeptides were desalted using C18 Zip Tips according to the manufacturers instructions and then dried for further MS analysis.

1.2 LC-MS/MS Analysis

1.2.1 Mass Spectrometer

The tryptic peptides were dissolved in solvent A, directly loaded onto a home-made reversed-phase analytical column (15-cm length, 100 μ m i.d.). The mobile phase consisted of solvent A(0.1% formic acid in water) and solvent B (0.1% formic acid, 80% acetonitrile/in water). Peptides were separated with the following gradient:0-0.75 min, 4.0%B; 0.75-0.90 min, 4.0%-8.0%B; 0.90-1.35 min, 8.0%-8.5%B; 1.35-20.85 min,8.5%-22.5%B; 20.85-31.35 min, 22.5%-35%B; 31.35-31.95 min, 35.0-55.0%B;31.95-32.70 min,55.0-99.0%B;32.70-34.00 min,99.0%B, and all at a constant flow rate of 400 nl/min on a Vanquish Neo UPLC system (ThermoFisher Scientific). The separated peptides were analyzed in Orbitrap Astral with a nano-electrospray ion source. The electrospray voltage applied was 1900 V . Precursors were analyzed at the Orbitrap detector, and the fragments were analyzed at the Astral detector. The full MS scan resolution was set to 240000 for a scan range of 700-2000 m/z. The MS/MS scan was fixed first mass as 120.0 m/z at a resolution of 80000. The Cycle Time was set as 0.6 s. Automatic gain control (AGC) target was set at 100%, with an intensity threshold of 25000 ions/s and a maximum injection time of 5 ms.

1.2.2 Database Search

Raw data were processed using MSFragger (v.3.4) software, tandem mass spectra were searched against the Gallus_gallus_9031_PR_20240807.fasta (43711 entries) concatenated with reverse decoy database. Enzyme was set to strict trypsin, missed cleavage was set to 2, respectively. The length range of the peptide was set to 7-50. Carbamidomethyl on Cys was specified as fixed modification. Acetylation on protein N-terminal, oxidation on Met were specified as variable modifications. Set mass offsets to the default list of glycosylated modifications. False discovery rate (FDR) of protein, peptide and PSM was adjusted to < 1%.

2 Bioinformatics Methods

2.1 Annotation Methods

2.1.1 GO Annotation

Gene Ontology analysis (GO analysis), a bioinformatics analysis method that provides statistical information by organically linking information about genes and gene products (e.g. proteins). In proteomics projects, GO is mainly used for the following purposes: 1) as a database for various information of proteins and genes; 2) to provide various information of proteins and genes, and to classify them according to the information; 3) as a tool to provide the most comprehensive information annotation and classification service for all proteins in the project.

GO analysis mainly includes three aspects: 1) Cellular component refers to the specific components of a cell that are considered as constituent parts of larger cellular structures within the GO system. For example, anatomically certain cellular structures (rough endoplasmic reticulum, nucleus, etc.), or a series of gene products such as the foundational structures of some complex components (ribosomes, protein dimers, etc.); 2) Molecular function refers primarily to

the chemical activities of molecules that can be manifested at the molecular level, including catalytic activities or binding activities; 3) Biological process is the term used to describe the ordered and specific execution of a particular function within an organism by a group of molecules.

The process of GO annotation involves using the eggNOG-mapper software to extract GO IDs from the identified proteins based on the EggNOG database, and then performing functional classification annotation analysis on the proteins according to cellular components, molecular functions, and biological processes.

2.1.2 Domain Annotation

The structural domain of a protein is a specific protein region in a protein that is conserved in sequence and can generally perform a function independently, and is a structural component of molecular function, generally consisting of 25 to 500 amino acids. These areas are relatively spatially compact, structurally stable, and capable of being independently folded into functional structures. A protein may have multiple domains, and a domain may also exist in multiple proteins. In the project data, protein structural domain annotation was performed on the identified proteins based on the Pfam database and the corresponding PfamScan tool.

2.1.3 KEGG Pathway Annotation

The Kyoto Encyclopedia of Genes and Genomes (KEGG) integrates currently known protein-protein interaction network information, such as pathways and related complexes (Pathway database), genes and gene products (Gene database), biological complexes and related reactions (Compound and Reaction databases), and other information. The KEGG pathways mainly include metabolism, genetic information processing, environmental information processing, cellular processes, human diseases and drug development. We annotate protein pathways based on the KEGG pathway database, and identify proteins through BLAST comparison, for each sequence, the annotation is based on the top-scoring comparison result.

2.1.4 Subcellular Localization Annotation

In eukaryotic tissue cells, proteins are exhaustively localized to various components based on differences in their binding to membrane structures. The major subcellular localizations in eukaryotic cells include: extracellular, cytoplasmic, nucleus, mitochondria, Golgi apparatus, endoplasmic reticulum, peroxisome, vesicle, cytoskeleton, nucleoplasm, nuclear matrix and Ribosome. Based on this, we used the WoLF PSORT software for predicting subcellular localization to annotate the submitted proteins. Compared to eukaryotic cells, prokaryotic cells generally have no intracellular membrane, no formed nucleus wrapped by a nuclear membrane, no intracellular chromosomes, DNA strands are unhelicalized and present in free form in the cytoplasm, and no membrane-bound organelles (e.g., mitochondria or chloroplasts) are present in the cytoplasm. In addition, according to the Berger's Manual of Bacterial Identification, prokaryotes are divided into four major groups: "Gram-negative eubacteria with cell walls", "Gram-positive eubacteria with cell walls", "Eubacteria without cell walls", and "Archaea". In view of this, we used PSORTb software to perform subcellular structure prediction analysis of the above four classes of proteins identified in prokaryotes.

2.1.5 COG/KOG Annotation

COG, full name is Clusters of Orthologous Groups of proteins. The proteins that make up each COG are assumed to be derived from an ancestral protein, Orthologs are proteins that are derived from different species, evolved from vertical lineages (species formation), and typically retain the same function as the original protein. COG means "cluster of homologous proteins" in Chinese. COGs are divided into two categories, one for prokaryotes and the other for eukaryotes. Those for prokaryotes are generally referred to as COG databases; those for eukaryotes are generally referred to as KOG databases. Compared to other databases, such as NCBI's COG database, EggNOG provides a more comprehensive classification of species and more homologous protein sequences, with phylogenetic tree construction and functional annotation for each homologous gene cluster.

2.1.6 Reactome Annotation

Reactome is a freely available open-source relational database that contains relationships between signaling and metabolic molecules and their organized biological pathways and processes. The core unit of the Reactome data model is reaction. The entities involved in the reaction (nucleic acids, proteins, complexes, vaccines, anti-cancer drugs, and small molecules) form a biological network of interactions and are grouped into pathways. Examples of biological pathways in Reactome include classic intermediary metabolism, signal transduction, transcriptional regulation, apoptosis, and diseases. Pathway information for multiple species is included in the database, and this project only annotates and analyzes pathways for specific selected species.

2.1.7 WikiPathways Annotation

The WikiPathways database is an open collaborative platform for collecting and disseminating biological pathway models used for data visualization and analysis. The database is equipped with pathway models for over 20 species, with seven species having more than 100 pathways. The human pathway collection contains over 800 pathways, covering 7,500 genes. In addition, WikiPathways also contains pathways for over 1000 metabolites. This project only annotates and analyzes pathways for selected species.

2.1.8 HallMark' s Signature Gene Sets Annotation

The Hallmark signature Gene Sets represent and summarize specific, well-defined biological states or processes. These gene sets are generated through a computational method based on identifying gene set overlaps and retaining genes that display coordinated expression. Better representation of a wider range of biological processes and diseases, these hallmark gene sets reduce noise and redundancy in the analysis process. Only a subset of pathways for certain species are annotated and analyzed in this project.

2.1.9 Transcription Factor Annotation

By annotating the protein-coding gene information obtained, the corresponding transcription factors of the proteins are annotated based on the common databases of transcription factors and target genes, such as TRRUST and GTRD (limited to human and mouse).

2.2 Motif Analysis

The motif characteristics of modified sites were analyzed by software MoMo based on motif-x algorithm. The peptide sequences composed of 10 amino acids upstream and downstream of all identified modified sites (for phosphorylation modification, 6 amino acids upstream and downstream) were selected; The analysis background are the peptide sequences composed of 10 amino acids upstream and downstream of all potential modified sites (for phosphorylation modification, 6 amino acids upstream and downstream). When the number of peptide segments of a characteristic sequence is greater than 20 and the statistical test p value is less than 0.000001, it is considered that the sequence is one of the motif of the modified peptide segments.

2.3 Functional Enrichment

Fisher' s exact test was used to analyze the significance of functional enrichment of differentially expressed proteins (using the identified protein as the background). Functional terms with Fold enrichment>1.5 and P value <0.05 were considered as significant.

2.4 Enrichment-based Clustering

Cluster analysis based on protein functional enrichment of differentially expressed proteins (or different fold changes of differentially expressed proteins) is used to investigate their potential associations and differences in specific functions (GO, KEGG pathways, protein domains, Reactome, WikiPathways). First, collect the functional enrichment results of all protein groups, then filter out functions that are significantly enriched (P value < 0.05) in at least one protein group. The filtered P value data matrix is then subjected to a -Log10 transformation, followed by one-sided clustering analysis using hierarchical clustering (Euclidean distance, average linkage clustering) on the transformed dataset. The clustering relationships are visualized using a heatmap generated by the Heatmap function in the R package ComplexHeatmap.

2.5 Protein-protein Interaction Network

All differentially expressed protein database accession or sequence were searched against the STRING database for protein-protein interactions. Only interactions between the proteins belonging to the searched data set were selected, thereby excluding external candidates. STRING defines a metric called "confidence score" to define interaction confidence; we fetched all interactions that had a confidence score > 0.7 (high confidence). Interaction network from STRING was visualized in R package "visNetwork" .